

Floresta de Decisão Oblíqua

PCS 3838 – Inteligência Artificial – Escola Politécnica da USP

Gabriel Chaves Lopes Silva
Rodrigo Galvez Lima

12555839
12553733

Abstract

Este relatório descreve o desenvolvimento, a lógica de implementação e a avaliação empírica de uma Floresta de Decisão Oblíqua (oRF). Diferente das árvores ortogonais tradicionais que particiona o espaço de características com cortes paralelos aos eixos, as árvores de decisão oblíquas (oDT) utilizam hiperplanos de divisão baseados em combinações lineares dos atributos, o que se mostra geometricamente superior em problemas com fronteiras diagonais. Adotamos a Análise Discriminante Linear (LDA) em cada nó para aprender de forma supervisionada e local a matriz de projeção ótima. Nossos testes empíricos em conjuntos de dados com fronteiras oblíquas demonstram que a oRF proposta supera substancialmente a Random Forest tradicional em termos de acurácia, apresentando um compromisso favorável e escalável entre habilidade preditiva e custo de processamento.

1. Introduction

Árvores de decisão e Random Forests estão entre os algoritmos mais utilizados em aprendizado de máquina devido à sua simplicidade e capacidade de generalização. Contudo, árvores tradicionais realizam divisões ortogonais, o que pode limitar seu desempenho em problemas com fronteiras de decisão oblíquas. Neste trabalho, foi desenvolvida e otimizada uma Oblique Random Forest (oRF), utilizando projeções lineares para construir divisões mais expressivas. Além da implementação do modelo, foram avaliadas diferentes técnicas de otimização, analisando o impacto de cada uma na acurácia e no custo computacional.

2. Methodology

min_samples_leaf=2 (acurácia de 79,37%) para reduzir o risco de overfitting e garantir maior capacidade de generalização.

3. Experiments

(Ambiente de Execução: NumPy 2.4.6, Pandas 3.0.3, Scikit-Learn 1.9.0)

Nesta seção, avaliamos o impacto incremental das otimizações propostas no desempenho do modelo, utilizando a acurácia no conjunto de validação e o tempo de treinamento para 100 árvores como métricas.

Versão	Acurácia
Baseline	53.97%
+ Norm.	75.49%
+ Subsampling	76.01%
+ LDA	78.66%
+ Otimiz.	79.37%

Os resultados indicam que a normalização e o subsampling melhoram a acurácia reduzindo ou mantendo o tempo de execução. A introdução do LDA e das otimizações finais (incluindo múltiplas projeções) eleva a acurácia para 79.37%. Nota-se um aumento no tempo de treino para 60s, justificado pelo esforço computacional adicional necessário para a busca estocástica por hiperplanos discriminativos mais robustos.

4. Conclusions

Em síntese, este trabalho demonstra que o desempenho de uma *Oblique Random Forest* vai além de só implementar um algoritmo. Fatores como

2.1 Problem Definition

Seja o conjunto de dados $D = \{(x_i, y_i)\}_{i=1}^n$, onde $x_i \in \mathbb{R}^d$ representa o vetor de características e $y_i \in \{1, \dots, c\}$ denota o rótulo da classe [5]. O objetivo de uma oDT é particionar o espaço recursivamente dividindo o conjunto de amostras de cada nó em dois subconjuntos X_{left} e X_{right} [10, 18]. O split é parametrizado pelo vetor de pesos $w \in \mathbb{R}^d$ e pelo limiar $\tau \in \mathbb{R}$ [73]. A regra de roteamento de uma amostra x é dada por:

$$f(x) = \begin{cases} \text{ir para a esquerda, se } \langle w, x \rangle \leq \tau; \\ \text{ir para a direita, se } \langle w, x \rangle > \tau \end{cases}$$

2.2 Proposed oRF: Otimização do Random Forest Oblíquo

O modelo base inicial sofria com sensibilidade à escala e projeções não-supervisionadas (acurácia de 53,97%). Para mitigar essas limitações, implementou-se:

- Normalização Local: Média e desvio-padrão calculados por nó para garantir equidade de escala.
- Feature Subsampling: Amostragem de $\sqrt{m}$ características para descorrelação das árvores.
- Tratamento Degenerado: Prevenção de erros numéricos em nós profundos.
- LDA Supervisionado: Projeções lineares focadas na separabilidade das classes.
- Regularização: Parada precoce via `min_samples_split` e `min_samples_leaf`.
- Gini Otimizado: Busca de limiares com complexidade $O(n \log n)$ via contadores.
- Multi-Projeções: Teste estocástico de múltiplos hiperplanos por nó.
- Soft Voting: Agregação probabilística para suavização das previsões.

O ajuste de hiperparâmetros seguiu uma estratégia em duas etapas baseada em uma divisão estática (80% treino / 20% validação, seed 42). A busca ampla inicial (Coarse Grid Search) delimitou a região ideal com profundidades entre 15 e 20 e mais de 100 árvores. O refinamento focado (Fine-Tuning) avaliou 72 combinações de métodos de projeção, número de projeções por nó e parâmetros de regularização. A configuração ótima identificada utilizou o método LDA supervisionado, profundidade máxima de 18, e `n_projections=5`. Embora o topo do ranking de validação tenha atingido 80,25% com folha unitária (`min_samples_leaf=1`), optou-se pela configuração conservadora com

o pré-processamento dos dados, as técnicas de otimização e o conhecimento do domínio do problema influenciam diretamente os resultados obtidos. Mais do que desenvolver uma *Oblique Random Forest*, o projeto permitiu consolidar os conceitos teóricos vistos em aula com a aplicação prática, mostrando o quanto a construção de um modelo eficiente depende da combinação de todos esses elementos.

References

Huang, Q., Ko, T., Zhuang, Z., Tang, L., and Zhang, Y. (2025). *HiRA: Parameter-efficient hadamard high-rank adaptation for large language models*. In International Conference on Learning Representations (ICLR), 2025.

Klabunde, M., Wald, T., Schumacher, T., MaierHein, K., Strohmaier, M., and Lemmerich, F. (2025). *Resi: A comprehensive benchmark for representational similarity measures*. In International Conference on Learning Representations (ICLR), 2025.

Menze, B. H., Kelm, B. M., Splitthoff, D. N., Koethe, U., and Hamprecht, F. A. (2011). *On Oblique Random Forests*. European Conference on Machine Learning and Principles and Practice of Knowledge Discovery in Databases (ECML PKDD), 2011.

Rauniar, S. (2026). *Jacobian Aligned Random Forests*. In International Conference on Learning Representations (ICLR), 2026.

Rank Acurácia Tempo(s) Parametros

1	0.8025	230.1	n_trees=150 depth=18 method=lda split=5 leaf=1 proj=5	<-- MELHOR
2	0.8025	229.1	n_trees=180 depth=18 method=lda split=2 leaf=1 proj=5	
3	0.8007	300.0	n_trees=150 depth=18 method=lda split=2 leaf=1 proj=5	
4	0.8007	294.1	n_trees=160 depth=18 method=lda split=5 leaf=1 proj=5	
5	0.7989	315.3	n_trees=150 depth=20 method=lda split=2 leaf=1 proj=5	
6	0.7989	213.4	n_trees=150 depth=20 method=lda split=5 leaf=1 proj=5	
20	0.7954	336.0	n_trees=160 depth=18 method=lda split=5 leaf=2 proj=5	
21	0.7954	165.8	n_trees=180 depth=20 method=lda split=2 leaf=2 proj=3	
22	0.7954	242.7	n_trees=180 depth=20 method=lda split=5 leaf=1 proj=3	
23	0.7954	242.6	n_trees=180 depth=20 method=lda split=5 leaf=2 proj=3	
24	0.7954	397.3	n_trees=180 depth=23 method=lda split=2 leaf=1 proj=5	
25	0.7954	272.9	n_trees=180 depth=23 method=lda split=2 leaf=2 proj=3	
26	0.7954	246.3	n_trees=180 depth=23 method=lda split=5 leaf=1 proj=3	
27	0.7937	198.3	n_trees=150 depth=18 method=lda split=5 leaf=2 proj=3	
28	0.7937	290.3	n_trees=150 depth=18 method=lda split=5 leaf=2 proj=5	
29	0.7937	206.0	n_trees=150 depth=20 method=lda split=5 leaf=2 proj=3	
30	0.7937	205.5	n_trees=150 depth=23 method=lda split=5 leaf=2 proj=3	

